KV260 端云 AI 互动体验平台

摘要

在博物馆的互动展台前，观众举起一只手，屏幕上便长出一段竹干。换到科技馆的体感游戏，同一只手可以操纵飞剑或划出切水果的刀迹。作品以 AMD Kria KV260 为核心，把八种游戏、八段锦与二十四式太极、动作水墨与照片水墨组织在同一台终端中。观众从首页选项目，用动作或手柄参与，用手机连接展台所在局域网，扫码登录并关联本次游玩，即可领取画卷与成绩。

平台把从相机图像到人体关节的主要计算放在 FPGA 的可编程逻辑（PL）上。我们用 SystemVerilog 设计前处理电路，按人体区域读取 YUYV 图像，以双行缓存复用邻域像素，在七级流水线内完成颜色转换、双线性缩放和 INT8 查表量化。DMA 将张量写回内存，板端同步输出缓冲，再经 VART 提交给 PL 内的 AMD B4096 DPU 运行官方 Hourglass 姿态模型。ARM 还原关节位置，按动作轨迹、速度与持续时间驱动笔墨和游戏。36 组板端对照中，两条前处理路径生成的输入张量及后续关节热图均逐字节一致。1080P 主人体区域的源读取量减少 43.6%，ARM 热图解码平均耗时从 6.540 ms 降至 5.135 ms。

KV260 还调用 DeepSeek API，向观众解释当前项目、推荐可执行的绘画步骤，并依据已完成的游戏记录给出复盘建议。动作识别在本地连续运行，联网助手在后台处理提问，使观众能够边参与、边了解动作与作品之间的关系。

第一部分 作品概述

1.1 功能与特性

平台按娱乐、健康、创作组织 12 个项目。娱乐包含御剑山河、格斗、水果忍者、太鼓音游、超级玛丽、地铁跑酷、仙剑奇侠传和赛车；健康提供八段锦与二十四式太极的示范、选式及基础跟练；创作支持人体动作绘画和照片水墨制作。观众可用体感或手柄选择玩法，也可在 DeepSeek AI 助手中点击“怎么玩”“怎么操作”“给点建议”，或用手机输入具体问题；人体水墨可获取分步创作方案，完成游戏后可查看成绩复盘。系统保留暂停恢复、独立存档和游客档案，首次使用手机服务时，观众在同一局域网扫码，登录或注册并关联本次游玩，即可上传照片、预览作品和领取成绩。

1.2 应用领域

teamLab《彩绘海洋》让观众给纸上的鱼着色，再在数字海洋中看到自己的鱼与其他人的作品一同游动[8]。本作品面向博物馆与科技馆展台，关注观众离开画桌后如何用全身动作参与。观众可展臂画山、举手生竹，或跟随示范练习八段

锦与太极。在体感游戏中，同一双手又可以挥切水果、击鼓。初次体验者可向 AI 助手询问动作要领，结束后用手机带走自己的画卷和成绩。

1.3 主要技术特点

系统以 FPGA PL 为视觉感知计算底座：自研前处理以七级定点算术核、ROI 坐标生成、16KiB 双行缓存、768 项量化 ROM 和 AXI 突发 DMA 构造模型输入，B4096 DPU 完成 Hourglass INT8 推理。ARM 通过 NEON 精确解码、ROI 质量选择和骨架时序建模生成连续量、事件与状态；CPU 与 Mali 分别承担二维、三维绘制。KV260 后台调用 DeepSeek API，利用本地项目事实、候选创作方案和成绩摘要组织上下文，以 JSON 契约、标识校验和本地展开完成 AI 引导。异步队列、内容缓存、游客会话和板端/手机共享服务连接感知、交互与成果管理。

1.4 主要性能指标

指标	技术参数或测试结果
PL 前处理算术核	7 级、II=1；约 100MHz
模型输入/输出	256×256×3/64×64×16 INT8
实板数值对照	36 组张量与热图逐字节一致
热图精确解码	均值 5.135ms；275 组一致
真人姿态更新	18.238FPS（40 秒水墨）
三维窗口渲染	跑酷 28.49/赛车 43.07FPS
DeepSeek 接入	12 个项目入口；8 次历史 API 调用

1.5 主要创新点

（1）七级位精确 PL 流水联合实现颜色、插值与量化，36 组实板张量及热图一致。

（2）ROI 几何驱动双行缓存与 DMA，1080P 主 ROI 源读取量降低 43.6%。

（3）双三次峰值上界结合 NEON 精确剪枝，解码平均耗时降低 21.5%。

（4）骨架时序统一生成连续量、事件与状态，复用到多种体验。

（5）将 PL 姿态感知与 DeepSeek 语义服务分层协同，以本地事实约束 AI 讲解、创作引导及成绩复盘。

1.6 设计流程

需求与 12 项目流程定义→确定相机、Hourglass 及 DPU 配置→建立 CPU 数值参考→设计 PL 流水、行缓存与 AXI 接口→RTL 验证与整板实现→实板张量和热图对照→构建动作语义与游戏适配→集成课程和照片创作→组织 DeepSeek

项目上下文与 JSON 契约→接入异步服务及板端/手机界面→完成回归、真实 API 联调与交互检查。

第二部分 系统组成及功能说明

2.1 系统整体介绍

平台由 PL 视觉计算、ARM 动作与应用处理、图形显示、游客服务及云端语义五个部分协同组成。USB 相机经 PS 将图像写入 DDR，自研 PL 前处理经 DMA 写回 INT8 张量，ARM 同步输出并通过 VART 调用 PL 内的 B4096 DPU 执行 Hourglass 推理；ARM 解码关节并建立动作状态，驱动游戏、人体水墨和基础跟练。照片水墨由 KV260 独立工作进程处理导入图像，CPU 与 Mali 负责界面及二维/三维显示。AI 服务根据当前项目、用户问题或已完成游戏记录构造上下文，由 KV260 直接请求 DeepSeek，再将校验后的方案与建议呈现在板端和手机。PL 将像素计算与神经网络密集运算映射到专用硬件，ARM 围绕动作解释、交互调度和 AI 服务组织应用，形成职责清晰的异构体系。

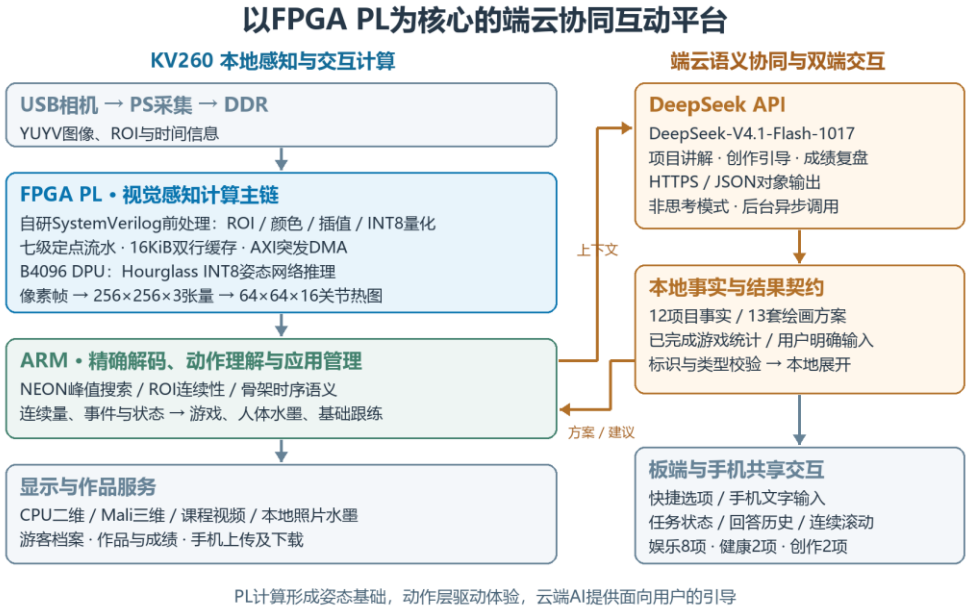


图 1 以 FPGA PL 为视觉感知计算底座的端云协同系统架构

体验项目	主要操作与玩法	结果与保存
人体水墨（身随墨动）	展臂画山、上举画竹梅、上托添叶花；动作速度改变笔墨	画卷保存、撤回与领取
御剑山河	右手操纵飞剑、自动射击、展臂释放技能	避弹、强化与首领挑战
格斗	侧移进退、拳掌攻击、踢腿、跳蹲和防御	攻防、能量与对局结算

体验项目	主要操作与玩法	结果与保存
水果忍者	双手挥切与连续刀迹	连击、双倍、冰冻、炸弹及分项成绩
太鼓音游（鼓动山河）	左右下挥、双鼓合击、胸前拍掌	多档判定、难度、练习和延迟调整
超级玛丽	体感移动与跳跃	关卡探索与独立进度
地铁跑酷	自然站立校准，侧移选道、起跳越障、下蹲滑铲	三轨避障、车顶路线与道具
仙剑奇侠传	动作控制方向、确认、返回与菜单	剧情交互与独立存档
赛车	方向盘姿态或身体倾斜转向，抬手漂移和释放道具	三圈竞赛、五名 AI、排名与成绩
八段锦指导	逐式示范、分解学习、完整跟练及自主练习	示范小窗、动作提示和练习记录
太极指导	二十四式选择、真人示范与基础跟练	分段回看、暂停继续和课程记录
照片水墨	手机上传或板端/U 盘选图;青绿淡彩与水墨两种画风	原图对照、高清 PNG 下载与游客归档

2.2 硬件系统介绍

2.2.1 FPGA PL 的核心作用与异构架构

FPGA PL 承担本作品最关键的视觉计算任务，包括团队自研的模型输入前处理与 B4096 DPU 神经网络推理[2]。USB 相机经 PS 将 YUYV 帧写入 DDR，PL 前处理完成 ROI 取样、颜色转换、双线性缩放和 INT8 量化，经 DMA 写回 256×256×3 张量。ARM 同步并复制输出，交由 VART 提交推理，再根据关节热图驱动动作。Mali 承担三维绘制。前处理需要对四邻域像素、三通道颜色和插值权重连续执行乘加与量化，DPU 则承担姿态模型的密集卷积，两者共同构成从原始图像到人体热图的硬件计算主链。团队把数据搬运、数值变换、模型输入和任务交接联合设计，使 PL 前处理与 DPU 推理能够独立调度并流水重叠，为游戏、绘画和跟练提供共享姿态基础，也为 ARM 承载交互和 DeepSeek 服务提供清晰的计算分工。

实现难点在于神经网络对尺寸、颜色、量化与缓冲区布局具有统一要求，而摄像头输出采用共享色度的 YUYV 格式，ROI 尺寸和位置又随人体区域变化。为此，团队以正式 C 前处理为数值基准，将坐标、颜色、插值、量化和存储协议逐层固化到手写 SystemVerilog 中，建立从像素输入到模型张量的位精确硬件实现。

模块	关键输入	关键输出与功能
PS 采集与 DDR	USB YUYV 帧、帧序号及时间	原始帧缓冲、stride 与 ROI 信息
自研 PL 前处理	源/目标地址、ROI、尺寸、stride、START	256×256×3 INT8 张量；任务 tag、周期和错误状态
B4096 DPU	[1,256,256,3] RGB INT8	[1,64,64,16] INT8 关节热图
ARM 处理系统	关节热图、时间戳、输入和宿主命令	17 槽位姿态接口、动作事件、规则及二维画面
Mali GPU/显示	跑酷与赛车的几何、材质、HUD	GLES2 完整帧，经显示链路输出
音响与可选手柄	游戏音频；按键、摇杆和菜单操作	声音反馈与体感/手柄双模式操作



图 2 FPGA 前处理数据通路与 ROI 双行缓存

图 2a—图 2e 展示终端的 KV260 主机、摄像头、声音反馈与手柄输入设备。



图 2a KV260 主机开盖及外部连接



图 2b USB 摄像头与固定支架



图 2c KV260 板卡、散热与接口特写



图 2d 音响与声音反馈设备



图 2e 游戏手柄与操作输入

2.2.2 七级定点流水与模型专属量化

算术核心对四个邻域像素并行处理，并按运算依赖划分为七级：S0 计算 20 项颜色常系数乘积；S1 依据 BT.601 有限范围规则完成 RGB 恢复及 0—255 饱和；S2、S3 完成横向插值的乘法和累加；S4、S5 完成纵向插值及统一舍入；S6 完成三通道查表量化。颜色转换采用 Q20 定点系数，亮度使用 max(Y−16,0)，色

度以 128 为中心；乘积与累加保留 32 位有符号中间值，兼顾极端色度、饱和边界和舍入精度。



图 3 七级定点算术流水与逐拍推进

设计将“四邻域分别完成颜色转换与饱和→横向插值→纵向插值→统一舍入”的运算顺序固化到寄存器边界。对任一 RGB 通道，设 c00、c10、c01、c11 为四个邻域像素完成颜色饱和后的 8 位通道值，a、b 分别为 Q11 横向和纵向插值权重，则 $h0=(2048-a)c00+a\cdot c10$，$h1=(2048-a)c01+a\cdot c11$，输出 $c=\lfloor[(2048-b)h0+b\cdot h1+2^{21}]/2^{22}\rfloor$。横向累加结果保留 11 位小数，纵向乘加后统一舍入，既能分级安排乘加关键路径，又保持与软件输入完全相同的数值结果。

模型输入的小数位数为 7，三通道均值为[110.3385，113.22，112.302]，缩放系数为 0.00392157。对通道 $k\in\{R,G,B\}$，设 p_k 为插值后的 8 位通道值、μ_k 为对应均值，量化公式为 $q_k=\mathrm{clip}(\mathrm{trunc}((p_k-\mu_k)\times0.00392157\times128),-128,127)$，其中 trunc 表示向零截断。团队按 float32 运算次序将该映射离线展开为每通道 256 项 ROM，共 768 项，并用独立标量 C 参考逐项核对。运行时通过 RGB 值直接寻址量化结果，以查表替代逐像素浮点归一化。连续供数时算术核延迟 7 拍、启动间隔 1 拍；全局推进使能同步保持数据、32 位 tag、last 与 valid，在输出反压下维持整条流水的像素身份与顺序。

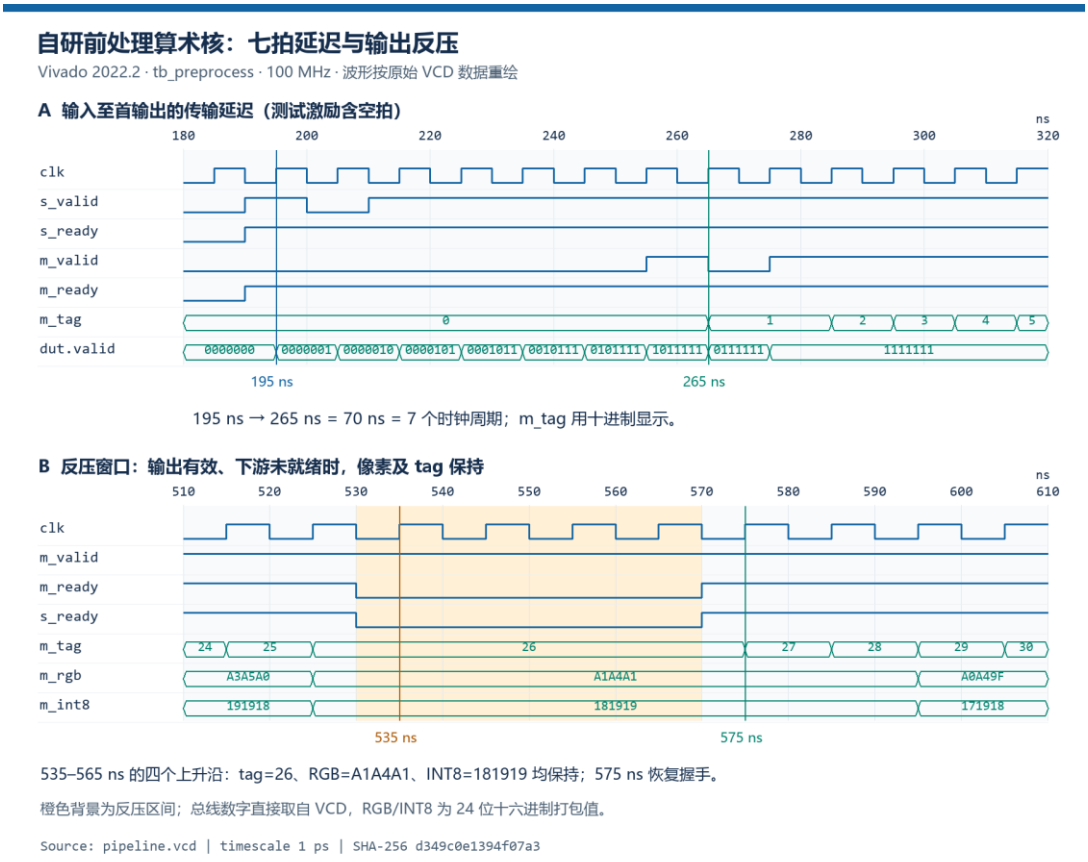


图 3a 自研七级算术核仿真波形，100MHz 时钟下的 7 拍传输延迟，以及输出反压时像素数据与 tag 的同步保持（按 Vivado 2022.2 原始 VCD 重绘）。

2.2.3 无除法 ROI 坐标生成与双行缓存

针对固定 256×256 模型输入，团队将半像素缩放坐标转化为精确整数计算。以横向为例，输出位置 u、ROI 起点 x_r 和宽度 W_r 对应 Q9 坐标 $X=512x_r+(2u+1)W_r-256$；将 X 约束到 ROI 边界后，整数部分给出源像素位置，低 9 位左移 2 位生成 Q11 插值权重。纵向采用同构逻辑，通过乘加、比较和移位完成坐标生成，消除通用除法器，并覆盖非方形 ROI、奇数起点及边界重复取样。

存储侧设置两个 2048×32 位同步双口行缓存，总容量 16KiB。行号标签决定数据复用与替换；同一源行被连续输出行重复使用时直接命中缓存，1 像素高 ROI 与放大取样同样通过行标签完成复用。地址逻辑依据 YUYV 的 Y0/U/Y1/V 分组及像素奇偶位提取四邻域，正确处理相邻像素跨 32 位分组。缓存以 READ/OFFER 两相调度，每两拍提交一个邻域样本；复位仅清有效标签和状态，保留规范同步 RAM 结构。

团队进一步把整行搬运优化为 ROI 有效行段搬运：读取范围覆盖 ROI 所需 YUYV 分组及右邻域，不搬运行尾 padding 和无关背景。1080P 主 ROI 的源读取量由 1,966,080 字节降至 1,107,968 字节，减少 43.6%。该设计把裁剪几何直接用于 DDR 访问组织，在维持同一模型输入的同时降低前处理数据搬运压力。

2.2.4 AXI 突发传输与原子任务控制

自研 DMA 采用 32 位 AXI4 INCR 突发，每次最多 256 拍，遇 4 KiB 边界自动拆分。写通道将四个 24 位 RGB INT8 像素紧密打包为三个 32 位字，连续写出 196,608 字节。逻辑跨突发保存余数字节，保持 R、G、B 顺序和字节写选通。在实测 KV260 互连中，写缓存备齐一个突发后先通过 AW 通道提交地址，地址握手完成后才经 W 通道发送数据，最后等待 B 通道的写响应。

任务控制同时跟踪像素序号、last、读写响应与完成状态。正常完成以最终像素交付和最后 B 响应共同确认；遇到 RRESP/BRESP 错误、异常 RLAST 或取消，状态机排空已发事务，再统一回收任务。AXI-Lite 寄存器支持 AW/W 独立到达、WSTRB、反压和错误响应；影子配置在 START 时原子锁存，活动任务始终使用同一组地址、几何参数与标签。软件通过 UIO 核对完成状态及任务标签，再将 XRT 输出缓冲区同步到主机侧，并复制为由推理任务独占的 INT8 数组。VART 在任务完成前持有该数组，使 PL 可以复用 DMA 缓冲区。

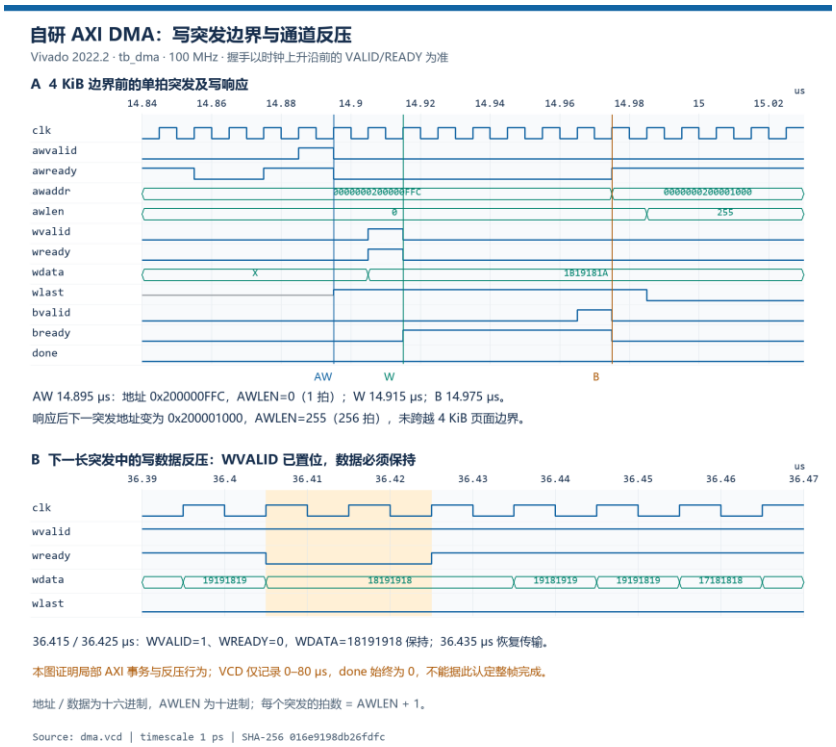


图 3b　AXI DMA 局部仿真中的 4 KiB 边界拆分、写响应与反压保持

2.2.5 平台重建、资源映射与整板闭合

平台集成从官方 2022.1 平台来源恢复，在 Vivado 2022.2 中重建适配 USB 相机的硬件工程。DPU 的 GP0 与前处理 DMA 经两入口 AXI 互连共享 PS HPC1，DPU 的 HP0、HP2 分别连接 PS HP1、HP3；300/600MHz DPU 时钟域与约 100MHz 前处理时钟域通过互连完成跨时钟、位宽和复位适配。团队适配了地址空间、设备树、XRT 元数据及 DPU 指纹。提交包提供源码和构建脚本，复现时先生成位流，再打包得到板端装载所需的 bin、dtbo 和 xclbin。

资源优化深入到 RTL 编码与综合映射。通过将写缓存的读地址选择移至存储器外、合并同步读表达式，DMA 写缓存由 8,591 FF、3,030 LUT 降至 212 FF、364 LUT 及 1 个 RAMB18，保持原有数据与握手时序。参赛版本中，含控制接口的自研 IP 独立综合使用 2,313 LUT、1,687 FF、36 DSP、8 个 RAMB36 和 4 个 RAMB18。参赛固件所用的整板设计完成 203,274 条网络布线，建立、保持及脉宽失败端点均为 0；36 组多分辨率、多 ROI 实板对照中，CPU/PL 输入张量及 DPU 输出热图逐字节一致。

2.3 软件系统与神经网络模型

2.3.1 多尺度神经姿态模型与异构部署

团队构建了“神经姿态感知—骨架质量评估—时序动作建模—游戏语义输出”的分层算法体系。感知骨干采用 AMD Vitis AI 2.5 官方 Hourglass MPII 预训练 INT8 模型[3]，利用多尺度特征聚合提取人体整体结构与局部关节信息，由 B4096 DPU 执行密集卷积，ARM 处理器承担热图解码、几何归一化与动作决策。网络输入为 NHWC 布局的[1,256,256,3]，输出为[1,64,64,16]关节热图；将 MPII 的左右肩、肘、腕、髋、膝、踝共 12 个对应关节按 COCO 点序填入统一 17 槽位业务接口的索引 5—16，其中肩、肘、腕、髋八个关节构成动作分析核心。[4]

Hourglass 编码路径通过逐级下采样扩大感受野，汇聚人体整体布局；解码路径通过逐级上采样和跨尺度特征融合恢复空间细节，使手腕、肘部等局部响应与肩臂结构共同参与定位[1]。各关节使用独立二维热图表达空间响应，保留位置峰值及其幅度，便于后续质量评估、坐标恢复和动作时序分析。运行时核对 DPU 指纹、张量形状、布局及定点位，并在异步执行期间保持输入缓冲所有权，实现 PL 张量与 VART 任务的连续交接。

2.3.2 保持数值语义的热图精确解码

热图解码同时影响关节定位、运动速度和动作时机。团队以模型正式后处理为基准，实现 A=−0.75 的双三次四倍上采样，采用半像素坐标映射、边缘钳位与有效区域找峰，保留峰值幅度及等峰时先较小 x、再较小 y 的决胜顺序。针对逐

通道展开 256×256 浮点热图的计算和存储开销，设计基于插值区域严格上界的峰值搜索：先在原热图最大点邻域建立当前最优值，再用每个 4×4 支撑域的最小值 m、最大值 M 估计可达到的峰值，仅对有竞争力的区域执行插值。

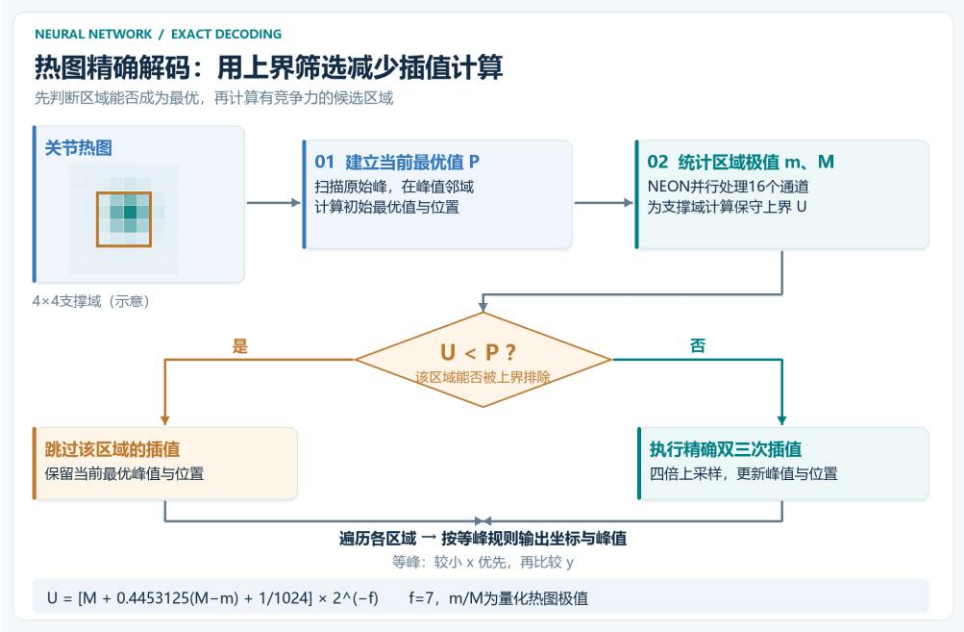


图 4 热图上界筛选与精确找峰流程

设两轴插值权重中负值绝对值之和分别为 N_x、N_y。对 A=−0.75 的核，两者均不超过 3/16；二维可分离权重中负值绝对值之和为 N_x(1+N_y)+N_y(1+N_x)，上限为 2×(3/16)×(1+3/16)=0.4453125。由全部插值权重之和为 1，支撑域内量化热图值的最小值 m、最大值 M 可给出峰值上界 U=[M+0.4453125(M−m)+1/1024]·2^(−f)，其中 f=7 为输出热图定点位置，1/1024 为浮点计算余量。实现采用可分离滑窗构造区域极值，ARM NEON 同时处理 16 个关节通道，将原始峰扫描与极值统计融合；区域插值复用横向中间量，避免构造完整的放大浮点热图。275 组真实、随机、常量、边缘及并列峰对照输出逐字节一致。正常服务负载下，两版本各交错执行 160 次，平均解码时间由 6.540ms 降至 5.135ms，P95 由 12.927ms 降至 8.741ms。

2.3.3 质量驱动 ROI 与骨架几何连续性

系统为一次姿态观测选取全高方形主 ROI 和边长为其 80%的上身备用 ROI。启用 PL 时，同一工作线程先发布主区张量，再准备备用张量。DPU 优先推理上一次保留的区域，按八个核心关节的峰值与坐标有效性评估骨架。质量不足时才增算另一区域，保留备用区域期间也会定时探测主区。选中的关节统一映回原图。恢复主区须满足几何一致性和持续时间条件，跨区域跳变会触发动作历史重置，避免把裁剪切换误判成一次挥手。

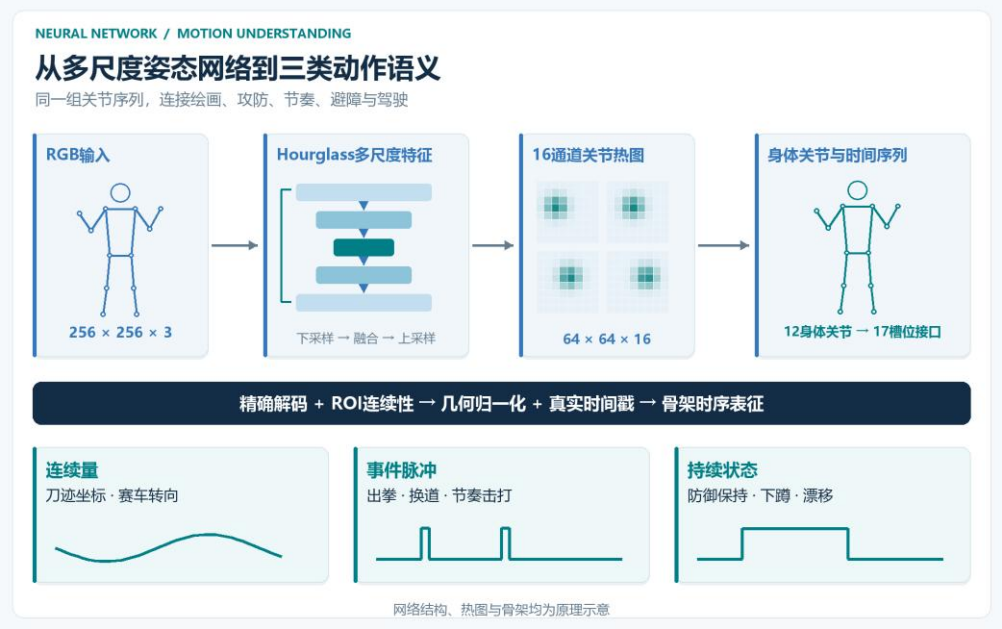


图 5 多尺度姿态表征与三类动作语义

2.3.4 骨架时序表征与混合控制模型

团队在神经网络输出之上建立轻量时序语义层，以肩宽为尺度、肩髋中心为身体锚点，提取相对位置、位移、径向与垂直速度、双臂协同和躯干倾斜。统一观测携带来源身份、帧序号与原始时间戳，动作计算由新观测推进。连续轨迹、转向量、单次操作事件及持续状态共享这一表征，再由各玩法的几何条件、滞回门槛、重新准备和冷却规则完成语义解码。该结构使视觉推理集中在统一感知底座，新增玩法能够直接组合已有动态特征与控制输出。

控制模型	时序特征与决策方法	形成的交互能力
动作水墨	髋中心对齐、肩宽归一化；八关节 32 时刻、16 维轨迹；带宽约束 DTW 与起势、方向、进度、终态联合判定	兼容动作快慢差异，识别完整动作并逐笔呈现
水果挥切	双腕连续轨迹；相邻真实观测形成刀路；结合水果历史位置计算相对线段—圆碰撞	保留挥切方向、快速穿越与连续切割
格斗攻防	腕肩相对位移、臂展比例、径向/垂直速度与双臂竞争；回收、冷却和短时招式缓存	区分直拳、上勾拳、双侧前推、防御和腿部动作
跑酷控制	肩髋共同侧移选道，上移幅度与速度触发跳跃，协同下沉触发滑铲	将连续身体运动转换为明确的换道、跳跃与滑铲指令
节奏击打	双手独立维护抬起、武装、过线和消耗状态；估计真实观测间的过线时刻；事件 ID 去重	一次挥动对应一次击打，动作时刻与音乐节拍对齐

控制模型	时序特征与决策方法	形成的交互能力
赛车转向	双腕斜率优先、躯干倾斜回退；死区与一阶平滑；漂移保持与道具脉冲分离	同时生成连续驾驶控制与单次操作事件

水墨识别通过因果分段组织自然动作，对轨迹作 32 时刻描述后，以 16 维局部 RMS 距离建立 DTW 代价矩阵，采用(1,0)、(0,1)、(1,1)递推和带宽约束，并结合类别间距与终态证据完成判决；C 原生实现使用双行工作区计算累计代价。分类轨迹负责形状比较，原始观测时间与运动速度继续驱动笔墨表现，形成动作辨识和动态呈现相结合的模型。跑酷以静站时的肩、髋中心为基准。两点同向侧移、平均横向位移达到 0.34 肩宽并稳定后选择侧道，回到中位即选中道。起跳时两点均须上升超过 0.11 肩宽，且上升速度均超过每秒 0.45 肩宽。赛车转向采用 steer=0.52·previous+0.48·target 平滑，使躯干及双腕动作形成连续操控。

2.3.5 源时间驱动与流水并行

节奏游戏在相邻真实观测间计算挥手过线时间，以来源、帧号和手别构造事件 ID，再与 GStreamer 音频 position 时钟对齐；全局击打线与胸前局部下挥线共同适应不同挥动幅度，双手合拢与双下挥采用竞争门控。系统将采集、PL 前处理、DPU 推理、动作语义和绘制组织为并行阶段，最新帧槽与有界预取控制输入积压，独立动作进程与下一帧推理重叠执行，按序号和世代确认结果。由此将网络定位精度、骨架运动连续性和游戏事件时机贯通为完整的体感智能链路。

2.3.6 异构渲染与应用宿主

二维体验采用预烘素材、有界文字缓存与原生像素合成，水果绘制接入面向 Cortex-A53 优化的 NEON Pixman；跑酷与赛车通过 Mali EGL/GLES2 执行三维渲染，使用 VBO 组织几何数据、ETC1 压缩纹理和 4×MSAA，按完整帧统一交换缓冲。赛车 HUD 依据内容变化增量上传，减少重复纹理搬运。视觉计算、游戏规则与图形绘制由 PL、ARM、Mali 协同完成，使模型处理与画面更新能够围绕各自的计算特点进行优化。

统一宿主通过结构化消息协调 ready、pause、resume、shutdown 及动作回执，管理菜单、体验切换、输入焦点和子进程回收。体感与手柄映射到一致的游戏指令，暂停、恢复及重开过程同步更新动作状态和游戏状态。平台跳跃与仙剑体验通过输入适配层接入游戏引擎，并管理各自进度与存档。主菜单按娱乐、健康和创作分层组织，手柄活动时优先获得导航控制，静止 3 秒后恢复手势，并清空旧停留进度。AI 入口分别接入游戏控制选择页、二级菜单、课程说明与照片页，返回时恢复原有项目上下文。

2.3.7 游客档案与成果领取

游客服务用 SQLite 记录游玩会话、成绩、练习与作品。观众将手机接入展台所在局域网，扫描当前主菜单的二维码，登录或注册后点击关联本次游玩，即可在本人账户中命名画卷、上传照片、查看 AI 回答，下载 PNG 和成绩。结束游玩时，终端归档本次成果，再创建下一位游客的会话。已归属的记录只对所属账户开放，终局提交中断后可按已记录的操作恢复。

2.3.8 传统文化创作与课程体验

人体水墨保留八关节时序识别与动作速度控制笔墨，在较大画布中逐笔呈现山水、竹和梅；真实绘制队列连接动作反馈与成画过程，手柄可选择笔画并调节笔墨速度。照片水墨采用 VGG 式编码器、AdaIN 固定风格统计和逐级卷积上采样解码器：编码器提取图像特征，AdaIN 调整通道统计，解码器重建国画风格图像[7]。团队在冻结编码器的基础上定向微调约 350 万参数的解码器，并将模型导出为 ONNX，由 KV260 独立 CPU 进程、ONNX Runtime 双线程执行，再结合天空留白、山石墨色及青绿赭色后处理输出两种画风。神经输入长边最高 960、总面积上限 524,288 像素，按 8 倍数对齐；最终 PNG 长边最高 1920。模型推理结束后释放运行时对象，再分配高清后处理数组，以阶段化内存复用控制峰值占用。

健康板块将八段锦与二十四式太极组织为课程、动作和练习状态。分解学习提供真人示范大视频，跟练页同时展示静音循环的真人小窗、动作骨架示意及使用者关节；暂停、继续、选式和回看由统一状态管理。动作提示读取本式所需关节及其观测质量，结合几何条件、阶段与保持时间形成基础反馈，练习结果归入游客档案。课程示范、姿态观测与交互引导共享同一终端，使传统文化体验从欣赏扩展到身体参与。



图 5a 八段锦第一式“两手托天理三焦”跟练实景。体验者抬起双臂，屏幕右侧的“我的动作”显示相应的上举姿态。

2.3.9 DeepSeek 端云协同 AI 助手

团队将大模型接入设计为平台的语义服务层：PL 负责视觉前处理与 DPU 姿态推理，ARM 完成关节解码、动作语义和应用执行，DeepSeek 理解用户问题并选择合适的讲解、创作方案或复盘建议。KV260 通过 HTTPS 直接调用 Chat Completions 接口，使用 DeepSeek-V4.1-Flash-1017，对应 API 模型名 deepseek-flash；关闭 thinking 模式并启用 JSON 对象输出，单次输出上限 1000 tokens、默认超时 20 秒。实时体感链路与联网任务分别调度，共同服务“看得见动作、理解体验意图、给出可操作引导”的互动流程。[5-6]

AI 上下文由当前任务动态构造。项目指南从与界面共用的 12 项目目录提取规则、操作、课程动作与建议，附加用户选择的“怎么玩”“怎么操作”“给点建议”及手机短文本。创作向导将山水、竹、梅和混合主题编码为 13 套合法方案，DeepSeek 依据创作意图选择 plan_id 并生成标题、简介，本地展开对应主题与动作步骤，观众再以体感或手柄逐步落墨。成绩复盘读取最近最多 8 局已完成游戏，把得分、连击、命中、失误或圈时等真实统计整理为带标识的事实条目，模型选择关联事实与下一局建议，再由本地数据展开显示。该设计将自然语言意图连接到已有游戏机制和绘画动作，使 AI 成为具体体验的引导入口。

为使大模型结果能够稳定接入嵌入式应用，团队建立“项目事实构建—提示词约束—JSON 解析—标识与类型校验—本地展开”的处理链。项目讲解与复盘使用 fact_ids、tip_ids 引用已提供的条目；创作使用 plan_id 引用经验证的动作方案。校验器检查字段集合、字符串长度、标识唯一性和候选归属，再由本地目录生成显示内容与操作说明。提交内容围绕项目事实、用户明确输入和选取的成绩

字段组织；密钥保留在 KV260 服务端配置中，手机通过游客服务发起任务。由此形成可追溯、能与本地操作对应的 AI 结果契约。

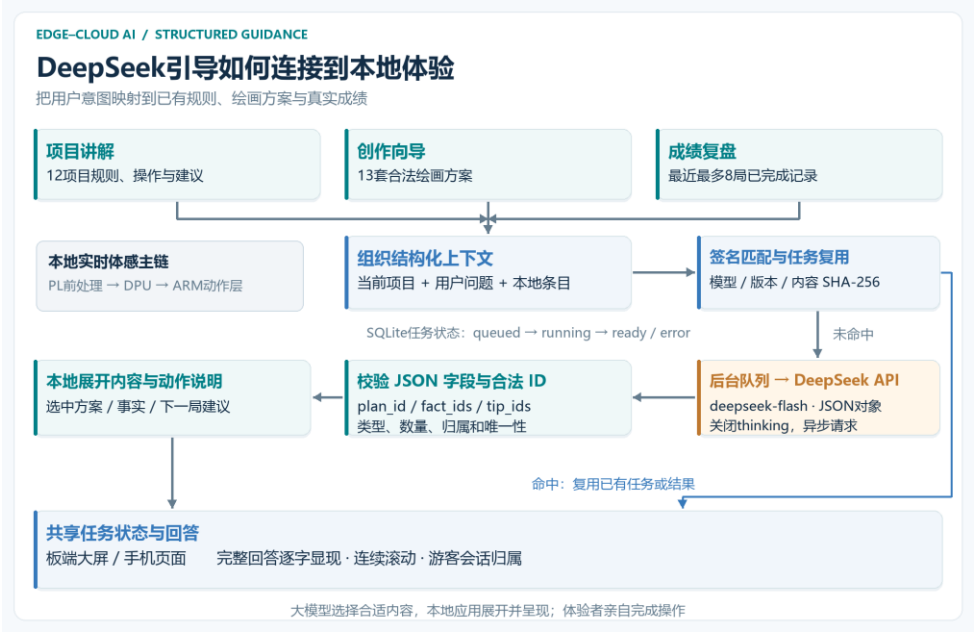


图 6 DeepSeek 结构化引导与本地功能衔接

运行层采用单后台工作线程与有界队列，SQLite WAL 持久化 queued、running、ready、error 状态；模型名、任务版本与规范化上下文参与 SHA-256 签名，同一游客的相同任务可复用已有结果。请求完成后再次核对会话归属，板端与手机读取同一任务记录。界面提供快捷选项和手机输入，提交后显示渐变“正在思考”；回答完成后按字显现、连续滚动，手动回看保持阅读位置，支持一键显示全文和清空建议。网络不可用时可查看本地项目说明。该机制将网络时延、游客切换、重复提交与阅读交互统一纳入应用状态管理，完成从模型 API 到现场体验服务的工程化接入。

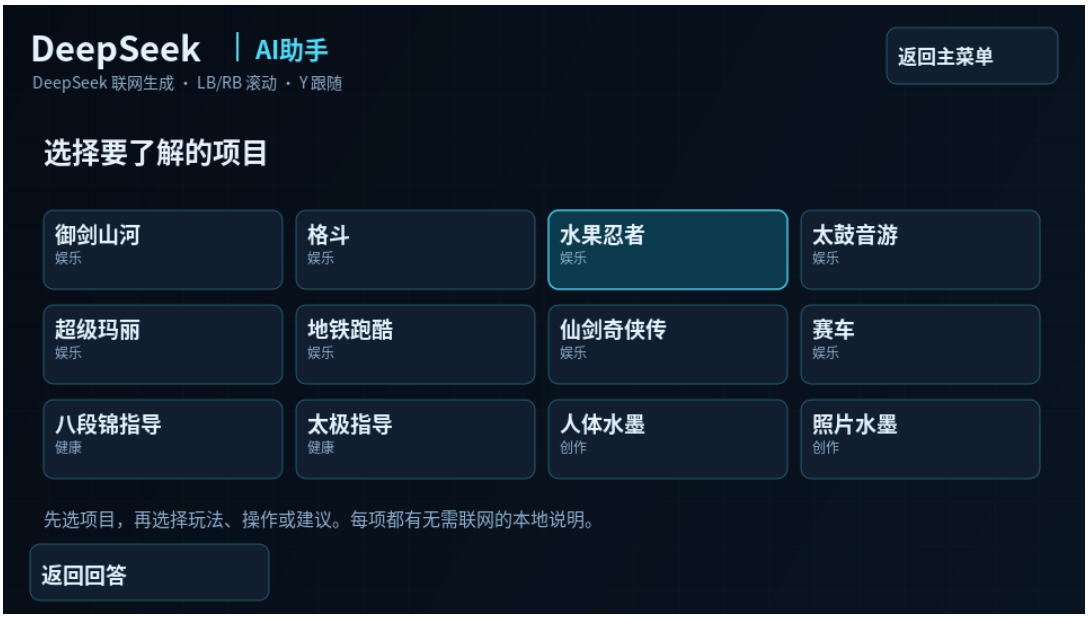


图 7 KV260 板端 DeepSeek AI 助手的 12 项目讲解入口

2.4 智能体辅助设计与仿真复现

为了让不同智能体复用同一套 FPGA 开发工具，我们把 Agent Bridge 的执行代码、参数说明和示例工程封装在 xilinx-bridge-cli 技能目录中。智能体从 SKILL.md 读取适用场景与步骤，通过 scripts/bridge.py 调用 20 个原生命令，也可查询 36 个工具的参数，再用 JSON 提交任务。普通命令行可以独立工作，工程路径以调用者的工作目录为基准。

以随包的灰度电路为例，先检测 Vivado 版本，再运行示例脚本建立临时工程并分别加入设计源和测试台。xsim 遍历 0 至 255 的全部灰度值，逐项比对实际输出与期望值。该示例已在 Vivado 2026.1 中通过，仿真摘要返回 pass。工程开发者可循同一入口复核工程文件、查询工具参数，再为自己的设计选择仿真或实现步骤。

第三部分 完成情况及性能参数

3.1 整体成果

系统已形成娱乐、健康、创作三类共 12 项目的统一终端，集成 PL 前处理、DPU 姿态推理、体感/手柄控制、二维/三维显示、课程示范、照片水墨与游客服务。PL 视觉链贯通采集帧、输入张量和关节热图，统一动作接口承载游戏、人体水墨与基础跟练；KV260 直连 DeepSeek，提供全项目讲解、创作方案和成绩复盘。观众可在终端选择和参与体验，用手机提出问题、上传照片、查看 AI 回答并领取作品与记录。主菜单、项目返回、暂停恢复、AI 清空及结果归档已纳入应用回归，形成计算、内容、交互和服务协同运行的完整作品。



图 8 KV260 板端娱乐、健康、创作主菜单与 DeepSeek 入口



图 8a 作品整机实物，含摄像头、KV260 主机、显示屏、音响与手柄



图 8a（侧视） 现场演示录像中的整机与操作区



图 8b 娱乐、健康、创作主菜单及 DeepSeek 助手现场显示

3.2 工程成果

工程类别	完成内容	交付成果
终端集成	KV260、USB 摄像头、显示设备、音响及可选手柄组成体验终端	设备连接方案与统一应用
FPGA 逻辑	自研算术核、ROI 前端、行缓存、AXI DMA、AXI-Lite 控制及 DPU 平台集成	SystemVerilog 源码、验证记录、实板版本实现报告及固件构建脚本
模型与动作	Hourglass INT8 部署、热图解码、ROI 质量选择、17 槽位姿态接口及跨游戏动作适配；静态照片风格模型微调与板端 ONNX Runtime 处理	模型配置、输入输出定义和动作处理模块
应用软件	娱乐、健康、创作 12 项目，统一宿主、课程视频、照片处理和游客服务	应用源码、课程管理、作品及成绩领取功能
端云 AI 服务	DeepSeek 直连、项目事实目录、创作方案、成绩复盘、JSON 校验及异步队列	AI 客户端、板端与手机界面、匿名联调统计
发布维护	固件与应用打包、安装部署、版本备份和回退	构建与安装脚本、部署及回退说明

参赛版本的整板资源与自研前处理综合用量

资源项	整板路由后用量/占比	自研前处理 OOC 综合
LUT	68,717/58.67%	2,313
FF	126,315/53.93%	1,687
DSP	746/59.78%	36
BRAM	86 Tile/59.72%	8 RAMB36＋4 RAMB18
URAM	56/87.50%	0

KV260 整板资源用量

Vivado 2022.2 / Routed

器件 xck26-sfvc784-2LV-c　　设计 kv260_ispMipiRx_vcu_DP_wrapper

资源类型	已用	可用	占用率	固定 / 禁用
逻辑资源				
CLB LUT	**68,717**	**117,120**	**58.67%**	0 / 0
逻辑 LUT	61,342	117,120	52.38%	0 / 0
存储 LUT	7,375	57,600	12.80%	0 / 0
分布式 RAM	2,744	—	—	0 / —
移位寄存器	4,631	—	—	0 / —
CLB 寄存器	**126,315**	**234,240**	**53.93%**	0 / 0
触发器	126,315	234,240	53.93%	0 / 0
片上存储				
BRAM 块	**86**	**144**	**59.72%**	0 / 0
RAMB36/FIFO	78	144	54.17%	0 / 0
RAMB36E2	78	—	—	— / —
RAMB18	16	288	5.56%	0 / 0
RAMB18E2	16	—	—	— / —
URAM	**56**	**64**	**87.50%**	0 / 0
运算资源				
DSP	**746**	**1,248**	**59.78%**	0 / 0
DSP48E2	746	—	—	— / —

— 表示原报告该字段为空。　　routed_utilization.rpt / 2026-09-14

图 8c　KV260 整板路由后资源用量（Vivado 2022.2）

图 8c 为参赛固件所用整板设计的路由结果，203,274 条网络布线完成，路由错误为 0。时序报告给出 WNS=0.000ns、WHS=0.003ns、WPWS=0.071ns，建立时间、保持时间与脉宽检查的失败端点均为 0。

图示为 2026 年 10 月 19 日由板端 Mali GLES2 生成的跑酷与赛车画面，展示场景构建、材质绘制、角色表现及界面叠加效果。

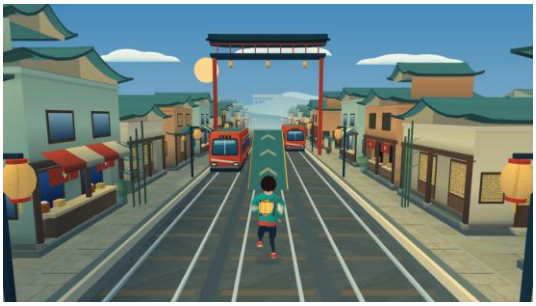


图 9 2026 年 10 月 19 日跑酷板端 Mali GLES2 确定性离屏渲染结果



图 10 2026 年 10 月 19 日赛车板端 Mali GLES2 确定性离屏渲染结果

3.3 特性成果量化

在同一 KV260 平台上回放 1080P 录像并固定单个 ROI，更换前处理后，包含 DPU 推理与热图解码的吞吐从 44.49 升至 47.19 FPS，张量及热图保持一致。跑酷与赛车窗口另以 960×540 分辨率和 4×MSAA 运行 35 秒，取预热 5 秒后的稳定区间。

测试项目	量化成果	测试配置
PL 算术与握手	426,632 组唯一输入；854,288 次 RGB/INT8 精确核对	连续输入与随机停顿仿真
ROI 与总线	655,360 次 ROI 输出核对	边界、padding、反压、跨页及错误恢复
PL/DPU 参赛版本实板对照	36 组输入张量与 DPU 热图逐字节一致	多分辨率、双 ROI，CPU/PL 前处理对照
前处理源读取量	1,966,080→1,107,968 字节，降低 43.6%	1080P 主 ROI
ARM 精确热图解码	平均 6.540→5.135ms；P95 12.927→8.741ms；275 组输出逐字节一致	原解码实现→NEON 优化实现；单线程，正常服务负载交错 160 次/版本
单 ROI 处理吞吐	720P：43.98→47.21FPS；1080P：44.49→47.19FPS	录制 YUYV 单 ROI，CPU/PL 前处理对照，含 DPU 与解码
应用回放	5 分钟平均 31.16FPS，9,345 帧无处理失败	固定输入回放，含动作处理与预览
水墨动作回归	127 段、162,996 帧；82 段正例完成落墨，45 段守卫样本无额外落墨	水墨开发回归集

测试项目	量化成果	测试配置
水墨真人体验	姿态更新 18.238FPS；完成画卷手机领取	2026 年 10 月 2 日，40 秒真人测试
水果窗口绘制	27.21→36.53FPS ； 1% 低帧 16.04→21.98FPS	密集合成输入，Gtk.Socket/Plug 窗口宿主
太鼓音游（鼓动山河）真人演奏	连续演奏 70.590 秒；GTK 绘制回调 21.703FPS	真人演奏记录
跑酷窗口渲染	平均 28.49FPS；1%低帧 18.23FPS；P95 帧间隔 46.70ms	960×540、4×MSAA、固定场景真实窗口
赛车 HUD 优化	37.57→43.07FPS ； 1% 低帧 15.97→20.46FPS；上传量降低 73.16%	同场景真实窗口；4 场景像素与 360 帧重建对照
赛车与集成回归	约 95 秒完成三圈自动驾驶；12 项核心通过；118 项集成中 117 项通过、1 项跳过	暂停、重开、退出、结果处理及 QR 条件检查
DeepSeek 真实 API 联调	6 次创作 JSON 验证＋2 次创作/复盘异步调用通过	2026 年 10 月 22 日 KV260 联调，匿名统计见 report/deepseek-validation.json
AI 入口与本地回归	12 个项目入口可用，当时板端 385 项回归通过	项目指南、入口返回、清空建议、等待动画与本地说明
高清照片水墨	三样本 worker 实测 138.08—143.71 秒；PNG 长边最高 1920	KV260、ORT CPU 双线程；横幅/方图/竖幅；含 worker 启动与输出写入
传统健身课程	八段锦与二十四式太极；视频播放、选式和跟练小窗操作通过	2026-10-22，板端联调及用户交互检查

第四部分 总结

4.1 可扩展之处

平台可围绕展览主题扩展画卷、角色、关卡与课程，把观众的创作意图和参观故事连接起来；通过难度分级、动作幅度与引导提示丰富亲子和研学活动。技术上，可继续以 PL 视觉计算和统一姿态接口支持新的反应、节奏与协作玩法，探索更轻量的姿态模型和访存优化；扩充 AI 项目知识及创作方案，使 DeepSeek 能结合展品主题和已有体验结果提供更贴合情境的讲解。游客作品、练习记录和游戏成绩可进一步衔接主题挑战与展览纪念服务。

4.2 心得体会

项目研发使团队进一步认识到，嵌入式人工智能系统的价值，来自模型计算、硬件实现与应用机制的协同。Hourglass 提供多尺度人体姿态表征，而稳定的游戏交互还需要精确的输入变换、高效的热图解码和符合玩法的动作解释。我们从

CPU 数值参考出发，将颜色饱和、插值顺序、定点精度和模型量化逐项落实到七级 PL 流水线，并通过随机停顿、边界 ROI 和实板张量对照，建立了从算法表达至硬件执行的完整设计方法。

性能优化同样要求理解计算与数据流之间的关系。行缓存提高像素复用，突发 DMA 组织连续传输，DPU 承担神经网络计算，ARM 完成姿态解码，CPU 与 GPU 分别处理二维和三维画面。面对资源、带宽与响应速度的共同约束，我们以资源报告、平均帧率、1%低帧和 P95 帧间隔定位瓶颈，针对数据搬运、重复绘制和长尾停顿逐项优化。赛车 HUD 增量更新在保持画面一致的同时降低 73.16%的上传量，使我们切实体会到系统结构优化的价值。

在智能体辅助开发中，我们将原来分散的 Vivado、Vitis 和板卡操作收拢到 Agent Bridge，通过命令行调用，并将入口、使用条件和操作步骤整理为标准 Agent Skill。调试一项改动时，可以先检查工具版本和工程配置，再运行仿真，依据波形、日志或退出状态决定下一步。对 AMD ROSS 这类辅助设计套件，我们建议把目标器件、工具版本、输入文件和产物位置显式列出，并分别显示仿真、实现和板级验证的状态。这样，评审或接手开发的人可以沿同一路径复查结果。

DeepSeek 接入使我们进一步理解了嵌入式 AI 的分层设计：PL 承担像素变换与姿态网络计算，ARM 连接动作与应用，大模型负责面向用户的语义选择。团队把项目说明、合法绘画方案和真实成绩整理为结构化上下文，通过 JSON 契约与本地校验将回答关联到现有功能，再用异步任务和游客会话连接板端与手机。这样的协作既发挥可编程逻辑的并行计算能力，也让观众更容易理解和参与游戏、创作与课程，形成具有文化表达、身体参与和 AI 引导的完整互动作品。

第五部分 参考文献

[1] NEWELL A, YANG K, DENG J. Stacked Hourglass Networks for Human Pose Estimation[C]//Computer Vision—ECCV 2016. Lecture Notes in Computer Science, vol. 9912. Springer, 2016: 483–499. DOI: 10.1007/978-3-319-46484-8_29. https://link.springer.com/chapter/10.1007/978-3-319-46484-8_29.

[2] AMD. DPUCZDX8G for Zynq UltraScale+ MPSoCs Product Guide: PG338, Version 4.0[EB/OL]. (2022-06-24)[2026-10-19]. https://docs.amd.com/r/4.0-English/pg338-dpu/Architecture-of-the-DPUCZDX8G.

[3] XILINX. Vitis AI Model Zoo: cf_hourglass_mpii_256_256_10.2G_2.5[EB/OL]. Version 2.5[2026-10-19]. https://github.com/Xilinx/Vitis-AI/blob/v2.5/model_zoo/model-list/cf_hourglass_mpii_256_256_10.2G_2.5/model.yaml.

[4] AMD. Vitis AI Library User Guide: UG1354, Version 2.5—Hourglass Pose Detection[EB/OL]. (2022-06-15)[2026-10-19]. https://docs.amd.com/r/2.5-English/ug1354-xilinx-ai-sdk/Hourglass-Pose-Detection.

[5] DEEPSEEK. DeepSeek-V4.1-Flash-1017: Wish-Driven Programming Made Real[EB/OL]. (2026-10-17)[2026-10-22]. https://api-docs.deepseek.com/news/news261017/.

[6] DEEPSEEK. JSON Output; Thinking Mode[EB/OL]. [2026-10-22]. https://api-docs.deepseek.com/guides/json_mode/ ; https://api-docs.deepseek.com/guides/thinking_mode/.

[7] HUANG X, BELONGIE S. Arbitrary Style Transfer in Real-Time With Adaptive Instance Normalization[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 1501–1510. https://openaccess.thecvf.com/content_iccv_2017/html/Huang_Arbitrary_Style_Transfer_ICCV_2017_paper.html.

[8] teamLab. 彩绘海洋 / Sketch Ocean[EB/OL]. [2026-11-03]. https://www.teamlab.art/zh-hans/w/sketch_ocean/.

附录 A　从综合报告定位写缓存瓶颈

团队在 Vivado 2022.2 中对同一器件、同一顶层 bodyink_preprocess_dma 做了两次独立综合。在原设计里，写入单元用两个读表达式访问同一块缓存。综合器用大量触发器保存数据，写入单元一项便占用 8,591 个触发器。

改动与验证

将读地址选择移到存储器外，只保留一个同步读端口后，综合器把缓存映射为一个 RAMB18。下面两列取自优化前后同一层次的综合报告。整板路由与含 AXI-Lite 控制的完整前处理 IP 用量见正文第 3.2 节。

比较项目	改动前	改动后
DMA 模块 LUT	4,570	1,896
DMA 模块触发器	9,320	941
DMA 模块 RAMB36 / RAMB18	8 / 3	8 / 4
DMA 模块 DSP	36	36
其中写入单元 LUT / 触发器	3,030 / 8,591	364 / 212

多用一个 RAMB18，DMA 模块减少了 2,674 个 LUT 和 8,379 个触发器。团队重新运行最长突发分别为 256 拍和 7 拍的 AXI 测试，覆盖反压、4 KB 边界和错误恢复。两组分别通过 344,067 和 196,611 次检查。

复核方法

在工程包 build 目录打开 dma-util-before.rpt 和 dma-util-after.rpt。层次表的顶行是整个 DMA，writer 行是写入单元。用表中的 FFs 和 RAMB18 两列即可复核缓存实现的变化。

附录 B　智能体协作与工程复现

从一次漏判到修复

2026 年 10 月 26 日，体验者反馈：“我刚刚试了一下，地铁跑酷下蹲动作似乎无法识别，你需要帮我解决这个问题。”开发智能体先用旧动作记录回放第一版修改，答复：“第一版修复在回放中暴露了回归：新增了一些滑铲响应，也漏掉了原来能识别的滑铲，因此尚未部署。”

第二版保留原有判定，对此前漏掉的下蹲动作单独补判。五轮回放保住原有的 9 次滑铲，补回 1 次，并检查了游戏是否执行动作。随后在 KV260 上进行 90 秒真人体验，记录到 11 次滑铲、6 次跳跃和 13 次换道。协作节选及检验步骤见 report/ai-collaboration.md。

如何把经验带到另一块板卡

将目标器件从建工程请求中分离，写入板卡配置文件。智能体先核对所选器件，再启动仿真。用同一灰度阈值测试台对 Basys 3、ZedBoard 和 KV260 三种工程配置分别检查 256 个输入。另用带 9 位输出寄存器的 8 位加法器做器件综合，三份报告均出现 9 个触发器。替换实物板时还应提供该板的时钟、引脚与电平约束。操作示例与失效条件见 skill/README.md。

从代码包复现

解压后先在根目录运行 python data/verify_evidence.py，核对保存的板端结果与黄金参考。再按 sim/README.md 生成固定种子的测试图像，运行 RTL 仿真。要重建整板，在 Vivado 2022.2 中按顺序运行 fpga 下的平台恢复与实现脚本，再用 Vitis 2022.2 打包固件。这个版本与项目采用的 Kria 平台源码和 DPU 配置配套。

在 KV260 上加载同一次构建生成的固件，核对 DPU 指纹 0x101000016010407，再使用已知输入逐字节比对 PL 输出。按 report/reproduction.md 配置相机、姿态模型及运行服务后，可从主菜单体验体感游戏、动作水墨与传统健身课程。